

<b>1. Introduction et Stratégie.....</b>	<b>1</b>
<b>2. Prétraitement des Données.....</b>	<b>1</b>
<b>3. Architecture et Justification du Modèle.....</b>	<b>1</b>
<b>4. Analyse des Performances et Détermination du Seuil.....</b>	<b>2</b>
<b>5. Limites et Pistes d'Amélioration.....</b>	<b>3</b>
<b>6. Conclusion.....</b>	<b>3</b>

## 1. Introduction et Stratégie

Ce projet vise à développer un algorithme capable de détecter des anomalies cardiaques (Classes R et V) à partir de signaux ECG. Le défi principal vient de la nature des données : le jeu de 5405 signaux est massivement déséquilibré, avec 97.8% de signaux normaux (Classe N) et surtout la présence d'anomalies inconnues (Classe V).

Nous avons donc opté pour une stratégie semi-supervisée avec comme algorithme un autoencodeur (AE), qui a été entraîné *exclusivement* sur les 5288 signaux normaux. L'hypothèse fondamentale est que le modèle apprendra à reconstruire parfaitement la "normalité". Par conséquent, lorsqu'il sera confronté à une anomalie (R ou V), il échouera à la reconstruire et l'erreur de reconstruction (MSE) servira de score d'anomalie.

## 2. Prétraitement des Données

Le prétraitement a été important pour garantir l'intégrité de l'approche semi-supervisée. Pour éviter toute fuite de données (data leakage), un StandardScaler (normalisation Z-score) a été entraîné (*fit*) uniquement sur les 5288 signaux de Classe N. Ce n'est qu'après cet entraînement que le scaler, désormais calibré sur la définition de la "normalité" a été utilisé pour transform l'intégralité du jeu de données.

Cette méthode assure que le modèle n'a aucune information statistique *a priori* sur les anomalies et y compris les anomalies connues (Classe R) ce qui garantit qu'il n'y a aucun biais d'entraînement.

## 3. Architecture et Justification du Modèle

Compte tenu de la contrainte d'inférence de 500ms sur Raspberry Pi, nous avons conçu un Autoencodeur Convolutionnel (AE-CNN) léger et efficace.

Cette architecture a été choisie pour deux raisons principales :

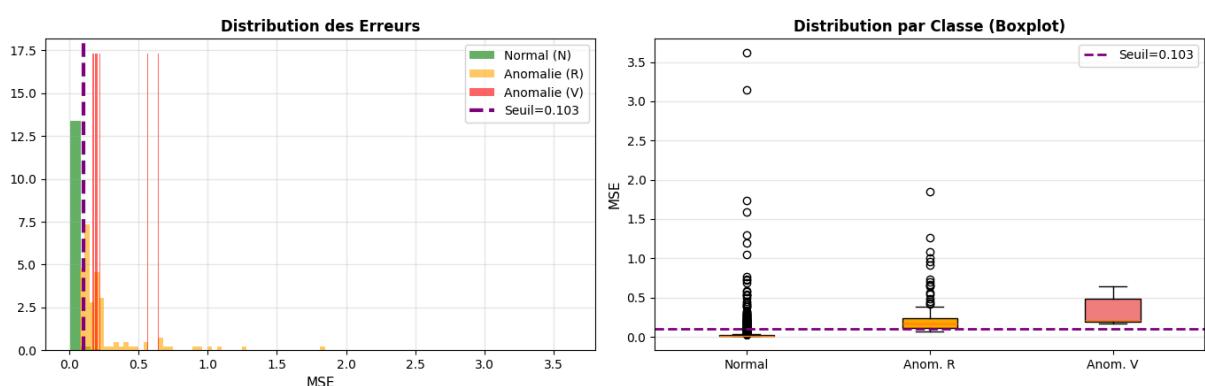
1. Gestion des Séquences (Conv1D) : Les signaux ECG sont des séries temporelles. Les couches Conv1D sont parfaites pour identifier des motifs locaux invariants dans le temps tels que les complexes P-QRS-T, indépendamment de leur position exacte.

2. Détection par Compression (Bottleneck) : L'architecture force les données à passer par un goulot d'étranglement de 8 filtres. Ce *bottleneck* est la clé : il est juste assez grand pour apprendre une représentation compressée des signaux normaux mais trop étroit pour mémoriser les détails spécifiques des anomalies.

Le modèle final ne compte que 34 641 paramètres, le rendant adapté à un déploiement sur des ressources limitées.

## 4. Analyse des Performances et Détermination du Seuil

Après l'entraînement (arrêté à l'époque 34 par EarlyStopping), nous avons calculé l'erreur de reconstruction (MSE) pour chaque signal. Comme le montre l'histogramme des erreurs



Le modèle sépare avec succès les signaux normaux (MSE faible, en vert) des signaux anormaux (MSE élevée, en orange et rouge).

Le choix du seuil de détection est un arbitrage critique. Nous avons analysé deux stratégies:

**Stratégie 1 : Seuil F1-Optimal (Équilibre)** Pour trouver le meilleur équilibre entre précision et rappel, nous avons déterminé le seuil maximisant le F1-Score.

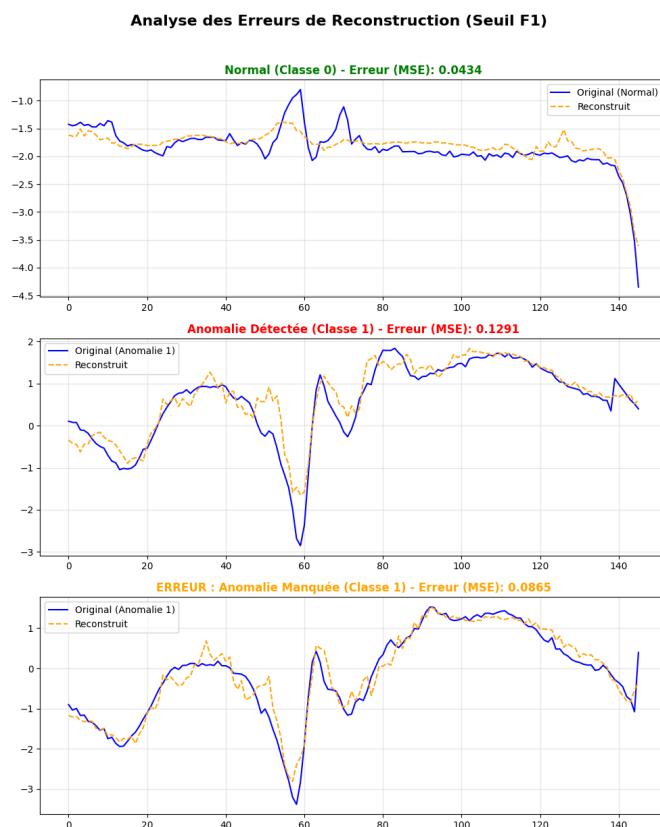
- Seuil F1 : 0.1385
- Performance : Ce seuil a permis d'atteindre un F1-Score de 0.663 et un AUC-PR (métrique fiable en contexte déséquilibré) de 0.489.
- Résultat par classe :
  - Classe V (Inconnue) : 100% détectée (6/6). C'est la validation principale de notre approche.
  - Classe R (Connue) : 91.9% détectée (102/111).
  - Classe N (Faux Positifs) : 1.9% des signaux normaux ont été incorrectement signalés (101/5288).

**Stratégie 2 : Seuil 100% Rappel (Sécurité Médicale)** Dans un contexte médical, manquer une anomalie (un Faux Négatif) est souvent inacceptable. Nous avons donc identifié l'erreur MSE la plus faible parmi toutes les anomalies (R et V), qui était de 0.0988.

- Seuil de sécurité : 0 . 0987 (fixé juste en dessous du minimum).
- Résultat par classe :
  - Classe R et V : 100% détectées (117/117).
  - Classe N (Faux Positifs) : Le coût de cette sécurité accrue est une augmentation des fausses alertes à 3.2% (167/5288).

## 5. Limites et Pistes d'Amélioration

Limites de l'approche (Inconvénients) La principale limite de cette méthode est illustrée par les 9 Faux Négatifs de la Classe R (avec le seuil F1).



Notre analyse visuelle confirme que ces anomalies manquées ressemblent *fortement* à des signaux normaux. L'autoencodeur a donc réussi à les reconstruire avec une faible erreur, les confondant avec la Classe N. C'est un inconvénient à l'apprentissage basé uniquement sur la "normalité".

### Vérification des Contraintes

- Robustesse au bruit : Nous avons testé le modèle en ajoutant du bruit aux signaux. L'erreur moyenne des anomalies est restée 8.5 fois supérieure à celle des normaux, montrant que le modèle (grâce au *bottleneck* et au *pooling*) est robuste au bruit mineur.

- Vitesse d'Inférence : Le test de performance (moyenne sur 10 essais) a révélé un temps d'inférence de 97.33 ms, ce qui respecte largement la contrainte de 500ms du Raspberry Pi.

Pistes d'Amélioration Pour conserver le rappel de 100% du Seuil 2 tout en réduisant le nombre de Faux Positifs (167), une approche hybride serait idéale :

1. Utiliser cet AE-CNN comme un filtre rapide (grâce à sa vitesse < 500ms) avec le seuil de sécurité (0.0988).
2. Envoyer uniquement les signaux qu'il a marqués comme "Anomalies" (les 117 vraies anomalies + les 167 fausses alertes) vers un second classificateur, plus petit et supervisé (entraîné sur N et R), pour affiner le diagnostic et rejeter les Faux Positifs.

## 6. Conclusion

L'autoencodeur convolutionnel semi-supervisé répond aux exigences du projet. Il est léger, rapide (inférence < 500ms), robuste au bruit et capable de détecter des anomalies inconnues (Classe V) avec 100% de succès.

Nous avons démontré l'arbitrage critique entre un seuil F1-Optimal (équilibré) et un seuil de rappel 100% (sécurité). Cette méthode est adaptable à d'autres signaux biomédicaux (ex: EEG) à condition qu'un ensemble de données "normales" fiables soit disponible pour l'entraînement.

## 7. Analyse d'Article Scientifique

Article : "Abnormal ECG detection based on an adversarial autoencoder" Source : Frontiers in Physiology (Septembre 2022)

Résumé:

Cet article utilise une méthode très similaire à la nôtre : il entraîne un modèle de type autoencodeur (un AE simple et un AE Adversarial, ou AAE) en utilisant uniquement des données ECG normales.

L'objectif est le même : le modèle apprend à reconstruire des signaux normaux. Lorsqu'un signal anormal est présenté et l'erreur de reconstruction est élevée ce qui le signale comme une anomalie.

Cet article est pertinent car il valide notre stratégie (entraîner sur N, détecter sur R et V) comme une approche efficace.